



计算机仿真及深度学习 在数学建模中的应用

刘新儒

2024/7/30



Contents.

目录

01

计算机仿真

02

深度学习算法

03

数学建模真题





计算机仿真



一个问题

我们做一个实验：把一个硬币掷一万次，统计两个面出现的次数。这样做很简单但却需要大量的时间，有没有一种较快的办法把这个实验完成呢？




利用计算机可以实现这一想法

- 生成一个在 $[0, 1]$ 中的随机数 a ,
- 如果 $a < 0.5$, 则认为是掷硬币出现了正面, 给计数变量 k_1 增加1;
- 如果, 则认为是掷硬币出现了反面, 给计数变量 k_2 增加1。
- 将该过程循环一万次即可。


上面就是一个计算机仿真最简单的例子!

[random_number_gen.py](#)




计算机仿真模拟图


计算机仿真的概念及介绍



随机数的产生




连续系统的仿真




排队系统的仿真

蒙特卡洛模拟



元胞自动机



生存游戏

计算机科学技术的迅猛发展，给许多学科带来了巨大的影响。计算机不但使问题的求解变得更加方便、快捷和精确，而且使得解决实际问题的领域更加广泛。计算机适合于解决那些规模大、难以解析化以及不确定的数学模型。

例如对于一些带随机因素的复杂系统，用分析方法建模常常需要作许多简化假设，与面临的实际问题可能相差甚远，以致解答根本无法应用，这时仿真几乎成为人们的唯一选择。在历届的美国和中国大学生的数学建模竞赛（MCM）中，学生们经常用到计算机仿真方法去求解、检验等。

- 计算机仿真就是根据一致的信息和知识，利用计算机模拟现实情况或系统演变过程，发现新的知识和规律，从而解决问题的一种方法。
- 计算机仿真被称为独立于理论研究和实验研究的第三种方法
- 仿真的基本思想是建立一个试验模型，这个模型包含所研究系统的主要特点。通过对这个实验模型的运行，获得所要研究系统的必要信息

- 代价小，时间短，可重复，参数设置灵活
- 是一种独特的数学模型
- 是一种求解许多实际问题和数学模型的简单方法，由于她不需要太多的数学知识，非常适合各类工程技术人员
- 计算机仿真仿的是“象”和“数”，因此要忽略许多具体的事务特征

物理系统仿真

对实际过程中功能相似的实物系统去模仿。

例如：电系统、机械系统、大坝承受能力仿真、原子弹爆炸威力仿真、军事演习、船艇实验、沙盘作业等。

系统演变仿真

对实际系统机器演变过程进行模仿。

例如：河堤垮塌后洪水蔓延程度仿真、海啸蔓延程度仿真、种群生长仿真、战争推演仿真等。

蒙特卡洛模拟

用计算机实现统计模拟或抽样，以获得问题的近似解。

例如：不规则图形面积&体积&圆周率计算、电脑围棋模拟等(被列为20世纪最伟大的10大算法之首)

离散事件仿真

例如：企业经营策略等。

如何将计算机仿真的过程作为数学模型表述

➤ 描述计算机仿真模型主要包括两个内容：

一是对系统关键数据计算方法的清晰表述；

二是对仿真的程序流程的描述，可以用算法步骤的形式，也可以用流程图。

注意：计算机仿真要靠计算机程序来实现，然而程序代码不能作为模型，且由于选择的系统语言不同，表述上也有很大的差异。

如何将计算机仿真的过程作为数学模型表述

- 产生模拟随机数
- 连续系统仿真
- 离散系统仿真
- 连续问题离散化
- 蒙特卡洛方法
- 遍历

要点： 过程明确、逻辑清晰

在 Python中，随机数生成器可以直接产生满足各种分布的随机数，命令如下：

1. 产生 $m \times n$ 阶 $[a, b]$ 均匀分布 $U(a, b)$ 的随机数矩阵：`random.uniform(low=a, high=b, size=(m,n))`

当只知道一个随机变量取值在 (a, b) 内，但不知道（也没理由假设）它在何处取值的概率大，在何处取值的概率小，就只好用 $U(a, b)$ 来模拟它。

2. 产生一个 $[a, b]$ 均匀分布的随机数：`random.uniform(a, b)`
3. 产生 $m \times n$ 阶均值为 μ ，标准差为 σ 的正态分布随机数矩阵：
`random.normal(loc=mu, scale=sigma, size=(m,n))`

3. 产生 $m \times n$ 阶均值为 μ ，标准差为 σ 的正态分布随机数矩阵：

`random.normal(loc=mu, scale=sigma, size=(m,n))`

当研究对象视为大量相互独立的随机变量之和，且其中每一种变量对总和的影响都很小时，可以认为该对象服从正态分布。

机械加工得到的零件尺寸的偏差、射击命中点与目标的偏差、各种测量误差、人的身高、体重等，都可近似看成服从正态分布。

4. 产生 $m \times n$ 阶期望值为 μ 的指数分布随机数矩阵 `random.exponential(scale=mu, size=(m,n))`

若连续型随机变量 X 的概率密度函数为
$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}, \text{ 其中 } \lambda > 0 \text{ 为常数, 则}$$

称 X 服从参数为 λ 的指数分布。指数分布的期望值为 $1/\lambda$

指数分布在排队论、可靠性分析中有广泛应用。排队服务系统中顾客到达率为常数时的到达间隔、故障率为常数时零件的寿命都服从指数分布。

例如：顾客到达某商店的间隔时间服从参数为0.1的指数分布

说明：指数分布的均值为 $1/0.1 = 10$ ，指两个顾客到达商店的平均间隔时间是10个单位时间.即平均10个单位时间到达1个顾客. 顾客到达的间隔时间可用 `exprnd(10)` 模拟。

5. 产生 $m \times n$ 阶参数为 λ 的泊松分布随机数矩阵：

`random.poisson(lam=lambda, size=(m,n))`

设离散型随机变量 X 的所有可能取值为 $0,1,2,\dots$,且取各个值的概率为

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots,$$

其中 $\lambda > 0$ 为常数，则称 X 服从参数为 λ 的泊松分布，泊松分布的期望值为 λ 。

泊松分布在排队系统、产品检验、天文、物理等领域有广泛应用。

更多随机数生成器及用法见（用法以官方帮助文档为准，而且跟具体的random包版本有关）

<https://numpy.org/doc/stable/reference/random/legacy.html>

排队论主要研究随机服务系统的工作过程。

在排队系统中，服务对象的**到达时间**和**服务时间**都是**随机的**。排队论通过对每个个别的随机服务现象的统计研究，找出反映这些随机现象平均特性的规律，从而为设计新的服务系统和改进现有服务系统的工作提供依据。

对于排队服务系统，顾客常常注意排队的人是否太多，等候的时间是否长，而服务员则关心他空闲的时间是否太短。于是人们常用排队的长度、等待的时间及服务利用率等指标来衡量系统的性能。



单服务员的排队模型：在某商店有一个售货员，顾客陆续来到，售货员逐个地接待顾客。当到来的顾客较多时，一部分顾客便须排队等待，被接待后的顾客便离开商店。设：

1. 顾客到来间隔时间服从参数为0.1的指数分布。
2. 对顾客的服务时间服从 $[4, 15]$ 上的均匀分布。
3. 排队按先到先服务规则，队长无限制。

假定一个工作日为8小时，时间以分钟为单位。求：

- (1) 模拟一个工作日内完成服务的个数及顾客平均等待时间 t 。
- (2) 模拟100个工作日，求出平均每日完成服务的个数及每日顾客的平均等待时间。



【符号说明】

w : 总等待时间;


c_i : 第 i 个顾客的到达时刻;

b_i : 第 i 个顾客开始服务时刻;

e_i : 第 i 个顾客服务结束时刻.

x_i : 第 $i-1$ 个顾客与第 i 个顾客之间到达的间隔时间

y_i : 对第 i 个顾客的服务时间




$$c_i = c_{i-1} + x_i$$

$$e_i = b_i + y_i$$


$$b_i = \max(c_i, e_{i-1})$$

模拟框图

[simu1.py](#)[simu2.py](#)

状态随时间连续变化的系统称为**连续系统**。对连续系统的计算机模拟只能是近似的，只要这种近似达到一定的精度，也就可以满足要求。

【例】追逐问题：如图,正方形ABCD的四个顶点各有一人.在某一时刻,四人同时出发以匀速 $v=1$ 米/秒按顺时针方向追逐下一人,如果他们始终保持对准目标,则最终按螺旋状曲线于中心点O.试求出这种情况下每个人的行进轨迹



【求解过程】

1. 建立平面直角坐标系: A(x1,y1), B(x2,y2), C(x3,y3), D(x4,y4).
2. 取时间间隔为 Δt , 计算每一点在各个时刻的坐标.

设某点在 t 时刻的坐标为: (x_i, y_i)

则在 $t + \Delta t$ 时刻的坐标为: $(x_i + v\Delta t \cos \alpha, y_i + v\Delta t \sin \alpha)$

其中
$$\cos \alpha = \frac{x_{i+1} - x_i}{d} \quad \sin \alpha = \frac{y_{i+1} - y_i}{d}$$

$$d = \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2}$$

3. 取足够小的 ε , $d < \varepsilon$ 时结束算法
4. 对每一个点, 链接它在各个时刻的位置, 即得所求运动轨迹

【计算程序】

```

v=1;
dt=0.05; % 时间间隔
x=[0 0 10 10];
y=[0 10 10 0];

for i=1:4
    plot(x(i),y(i),'.'),hold on
end

d=20;
while(d>0.1)
    x(5)=x(1);y(5)=y(1);
    for i=1:4
        d=sqrt((x(i+1)-x(i))^2+(y(i+1)-y(i))^2)
        x(i)=x(i)+v*dt*(x(i+1)-x(i))/d
        y(i)=y(i)+v*dt*(y(i+1)-y(i))/d
        plot(x(i),y(i),'.'),hold on
    end
end
end

```

```

import numpy as np
import matplotlib.pyplot as plt
v = 1
dt = 0.05 #时间间隔
epsilon = 0.10 #阈值

x = [0,0,10,10,0]
y = [0,10,10,0,0]

d = float('inf') #初始最大化距离
while d>epsilon:
    x[4] = x[0]
    y[4] = y[0]
    for i in range(4):
        d = np.sqrt((x[i+1]-x[i])**2 + (y[i+1]-y[i])**2)
        x[i] = x[i] + v*dt*(x[i+1]-x[i])/d
        y[i] = y[i] + v*dt*(y[i+1]-y[i])/d
        plt.plot(x[i],y[i],'-k.')
    plt.show()

```

[chase.py](#)[chaseImprove.py](#)

蒙特卡罗方法又称统计模拟法、随机抽样技术，**是一种随机模拟方法**，以概率和统计理论方法为基础的一种计算方法，是使用随机数（或更常见的伪随机数）来解决很多计算问题的方法。将所求解的问题同一定的概率模型相联系，**用计算机实现统计模拟或抽样，以获得问题的近似解**。为象征性地表明这一方法的概率统计特征，故借用赌城蒙特卡罗命名。



当所求问题的解是某个事件的**概率**，或者是某个随机变量的**数学期望**，或者是与**概率、数学期望有关的量**时，通过**试验的方法**得到该事件发生的**概率**、或该随机变量若干个具体观察值的算术平均。

当随机变量的取值仅为1或0时，他的数学期望就是某个事件的概率；或者说，某种事件的概率也是随机变量(仅取值为1或0)的数学期望。


通俗地说：

采样越多，越近似最优解

假如筐里有100个苹果，闭眼拿1个，挑出最大的。于是我随机拿1个，再随机拿1个跟它比，留下大的，再随机拿1个……每拿一次，留下的苹果都至少不比上次的小。拿的次数越多，挑出的苹果就越大，但我除非拿100次，否则无法肯定挑出了最大的。这个挑苹果的算法，就属于蒙特卡罗算法——尽量找好的，但不保证是最好的。

思考：如何用蒙特卡洛模拟法求圆周率 π ？


- 如图，红色线条为平面上圆心在原点的单位圆，圆的面积为 π ，黑色线条构成边长为2的正方形。



设相互独立的随机变量 X , Y 均服从 $[-1,1]$ 上的均匀分布，则 (X,Y) 服从 $\{-1 \leq x \leq 1, -1 \leq y \leq 1\}$ 上的二元均匀分布（即图中正方形区域上的二元均匀分布）

记事件 $A = \{x^2 + y^2 \leq 1\}$ ，则 A 事件发生的概率等于单位圆面积除以边长为2的正方形的面积，即 $P(A) = \pi/4$

➤ 蒙特卡洛算法求解圆周率



可得圆周率 $\pi = 4P(A)$.

而 $P(A)$ 可以通过蒙特卡洛模拟法求得，在左图中正方形内随机投点（即横坐标 X 和纵坐标 Y 都是 $[-1,1]$ 上均匀分布的随机数），落在单位圆内的点的个数 m 与点的总数 n 的比值 m/n 可以作为 A 事件的概率 $P(A)$ 的近似

随着投点总数的增加， m/n 会越来越接近于 $P(A)$ ，从而可以得到逐渐接近于 π 的模拟值

对于非线性规划问题：

$$\begin{aligned} \min & f(X) \quad X \in E^n \\ \text{s. t.} & \quad g_i(X) \geq 0 \quad i=1, 2, \dots, m \\ & \quad a_j \leq x_j \leq b_j \quad j=1, 2, \dots, n \end{aligned}$$



用蒙特卡洛求解得基本思想是：在估计的区域

$$\{(x_1, x_2, \dots, x_n) \mid x_j \in [a_j, b_j], j=1, 2, \dots, n\}$$

内随机取若干实验点，然后从实验点中找出可行点，再从可行点中选择最小点。

基本假设

试验点的第 j 个分量 x_j 服从 $[a_j, b_j]$ 内的均匀分布.

符号假设

P: 试验点总数;

MAXP: 最大试验点总数;

MAXK: 最大可行点数;

K: 可行点总数;


X^* : 迭代产生的最优点;

Q: 迭代产生的最小值 $f(X^*)$, 其初始值为计算机所能表示的最大数.

求解过程

先产生一个随机数作为初始试验点,以后则将上一个试验点的第 j 个分量随机产生, 其它分量不变而产生一新的试验点. 这样, 每产生一个新试验点只需一个新的随机数分量. 当 $K > \text{MAXK}$ 或 $P > \text{MAXP}$ 时停止迭代.

框图


[MonteCarlo.py](#)

➤ 优点:

1. 能够比较逼真地描述具有随即性质的事务的特点及物理实验过程;
2. 受集合条件限制小;
3. 收敛速度与问题的维数无关;
4. 具有同时计算多个方案与多个未知量的能力;
5. 误差容易确定;
6. 程序结构简单易于实现



➤ 缺点:

1. 收敛速度慢;
2. 误差具有概率性;
3. 在粒子运输问题中, 计算结果与系统大小有关;

因此, 在实验蒙特卡洛算法时, 要 “扬长避短”, 只对问题中难以用解析 (或数值) 方法处理的部分使用蒙特卡洛算法, 对那些能用解析 (或者数值) 方法处理的部分, 应当尽量使用解析方法。

元胞自动机（Cellular Automata）是一种时间、空间、状态都离散
的模型，具有强大的空间建模和计算能力，能够模拟具有时空特征的
复杂动态系统。

元胞自动机的基础就在于“如果让计算机反复地计算极其简单的运算
法则，那么就可以使之发展成为异常复杂的模型，并可以解释自然界
中的所有现象”的观点。




史蒂芬·沃尔弗拉姆(Stephen Wolfram)，生于1959年8月29日，是英、美籍 **计算机科学家、数学家、物理学家和商人**。因计算机科学，数学和理论物理学**杰出**的**贡献**而**闻名**。著名大学UIUC的兼职教授，**美国数学协会的首席研究员**。

软件公司Wolfram Research的**创始人**兼**首席执行官**，曾担任Mathematica和Wolfram Alpha应答引擎的**首席设计师**。

将Mathematica的编程语言扩展并改进为多模态的**Wolfram语言**。“Wolfram语言入门”一书向完全没有编程知识的人介绍该语言，并且**提供了一种计算思维**。

2016年，使用Wolfram语言参与了为电影“降临”(Arrival)**创造了外星人的语言**。



知乎

首页 学习 会员 发现 等你来答

2022 第 200 天

百科 讨论 精华 等待回答

如何看待Stephen Wolfram声称万物理理论已被发现？

 La Vie

全文一共一万六千多字，主要分为这几个部分：从简单规则开始；所有可能的规则；空间的维度；时间；因果关系（因果不变论）；相对论；黑洞和奇点；量子力学；终极规则；一些感想。读者可以根据感兴趣的题目进行阅读。... [阅读全文](#) ✓

▲ 赞同 6999


● 464 条评论

🔗 分享

★ 收藏

❤️ 喜欢

如何看待Stephen Wolfram声称万物理理论已被发现？

 sailing, We must know. We will know.

这篇文章从简单规则的迭代计算的角度（类似于生命游戏），能和所主要的物理学理论联系起来。从空间时间，到质量能量，从狭义相对论到广相，从基本粒子到黑洞奇点，从量子力学到因果不变性。虽然有些解释我没看懂，虽... [阅读全文](#) ✓

▲ 赞同 1873

● 121 条评论

🔗 分享

★ 收藏

❤️ 喜欢

如何看待Stephen Wolfram声称万物理理论已被发现？

 赵智沉, 冷眼看世界, 热心待他人。

（除了博客，我读了448页技术文档的大部分内容，两篇共124页的数学定义论文，还有 A New Kind of Science 第九章，基本理清了思路 and 细节。不过我懒得把所有图一张张贴过来，只贴必要的... [阅读全文](#) ✓

▲ 赞同 1617

● 123 条评论

🔗 分享

★ 收藏




❤️ 喜欢



WOLFRAM MATHEMATICA

全球现代技术计算的终极系统

可在桌面、
云端和移动中使用



<https://www.wolfram.com/mathematica/>

Mathematica是一款科学计算软件，很好地结合了数值和符号计算引擎、[图形系统](#)、编程语言、文本系统、和与其他应用程序的高级连接。很多功能在相应领域内处于世界领先地位，它也是使用最广泛的[数学软件](#)之一。Mathematica的发布标志着现代科技计算的开始。Mathematica是**世界上通用计算系统中最强大的系统**。自从1988发布以来，它已经对如何在科技和其它领域运用计算机产生了深刻的影响。

人们常说，Mathematica的发布标志着**现代科技计算的开始**。自从上世纪六十年代以来，在数值、代数、图形、和其它方面一直有个别的软件包存在。但是，Mathematica的基本概念是用一个连贯的和统一的方法创造一个能适用于科技计算各个方面的软件系统。实现这一点的关键之处是发明了一种**新的计算机符号语言**。这种语言能仅仅用很少量的基本元素制造出广泛的物体，满足科技计算的广泛性。这在人类历史上还是第一次。

当Mathematica1.0版发布时，《纽约时代报》写道：“这个软件的重要性不可忽视”；紧跟着《商业周刊》又将Mathematica评比为当年十大最重要产品。在科技界，**Mathematica被形容为智能和实践的革命**。



Enter what you want to calculate or know about



 NATURAL LANGUAGE

 MATH INPUT

 EXTENDED KEYBOARD

 EXAMPLES

 UPLOAD

 RANDOM

Compute expert-level answers using Wolfram's breakthrough algorithms, knowledgebase and AI technology

Mathematics ›



Step-by-Step Solutions



Elementary Math

x^2-1 Algebra



Plotting & Graphics

Science & Technology ›



Units & Measures



Physics



Chemistry



Engineering

Society & Culture ›



People



Arts & Media



Dates & Times



Words & Linguistics

Everyday Life ›



Personal Health



Personal Finance



Surprises



Entertainment

<https://www.wolframalpha.com/>

沃尔夫勒姆研究公司开发出的**新一代搜索引擎**，用户在搜索框键入需要查询的问题后，该搜索引擎将**直接**向用户**返回答案**，而**不是**返回**一大堆网页链接**。

基于 Wolfram 早期旗舰产品 **Mathematica**，一款囊括了计算机代数、符号和数值计算、可视化和统计功能的计算平台和工具包开发的。其数据来源包括学术网站和出版物、商业网站和公司、科学机构等等。

知识计算引擎软件，而**不是搜索引擎**。其真正的创新之处，在于能够马上理解问题，并给出答案。搜索词可以不是语法上完整的句子或词组，只需要包含关键词就可自动联想，实现了“模糊语义识别”。在被问到“珠穆朗玛峰有多高”之类的问题时，不仅能告诉你海拔高度，还能告诉你这座世界第一高峰的地理位置、附近有什么城镇，以及一系列图表。要是问“什么是升D大调”，可以把它演奏出来。

元胞自动机的特点

简单性和直观性 complexity $\neq$ complication

离散性；灵活性与开放性

易于与GIS、遥感数据处理等系统结合

元胞自动机的扩展

细胞空间：从无限到有限；从同质到非同质；从规则到不规则

细胞状态：表征地理实体或现象的指标、编码或等级的集合

邻域：从固定性到非固定性 多种多样


转换规则：从普遍到非普遍（分区）；从恒定性到变动性；从确定性到随机性，局部个体间相互作用-综合的多层次规则，时间概念与地理实体演化相一致，从规律性到不规律性，系统从闭合到开放。

元胞自动机 (CA) 与计算机科学的发展有密切的关系, 元胞自动机的出现为早期计算机的设计提供了依据。




- 元胞分布在按照一定规则划分的离散的元胞空间上;
- 系统的演化按照等间隔时间分布进行, 时间变量取等长的时刻点;
- 每个元胞都有明确的状态, 并且元胞的状态只能取有限个离散值;
- 元胞的下一时刻演化的状态值是由确定的转换规则所决定的;
- 每个元胞的转换规则只由局部领域内的元胞状态所决定。


- CA的核心是确定其**转换规则**，根据具体的需要解决的问题，转换规则的类型、结构等都有很大的不同。
- 邻域的类型主要有**摩尔邻域**和**冯诺伊曼邻域**两种，其半径的大小也需根据实际问题而定。传统CA模型中状态是离散的，但有学者也开始将其扩展为连续的（黎夏，叶嘉安，1999），以体现元胞的持续变化过程。



Von. Neumann



Moore



Extended Moore

1

元胞 (cell) 和元胞空间 (Lattice)

状态 (state) 和初始状态 (initial configuration)


2

3

领域 (Neighborhood)

转换规则 (Transition Rule)

4




- 元胞是元胞自动机最基本的组成部分;
- 一个元胞就是一个存储元件, 可以记录状态;
- 元胞自动机是定义在一个由具有离散、有限状态的元胞组成的元胞空间上的。


- 1维元胞空间



- 2维元胞空间



- 3维元胞空间






- 状态的数目是**有限的** (Number of states should be **finite**)




- 初始形态决定了各个元胞的初始状态


- 所有的元胞都在离散时间上进行变化。

 $t = 1$  $t = 2$ 

- 一个元胞的领域由其周围的元胞组成
- 冯诺依曼领域 (von Neumann Neighborhood)
- 摩尔领域 (Moore Neighborhood)




- 转换规则决定了元胞在下一个时刻的状态;
- 简单讲, 就是一个状态转移函数。




- 初等元胞自动机是状态集 S 只有两个元素 $\{s_1, s_2\}$ ，即状态个数 $k=2$ ，邻居半径 $r=1$ 的一维元胞自动机。由于在 S 中具体采用什么符号并不重要，它可取 $\{0, 1\}$ ， $\{-1, 1\}$ ， $\{\text{静止}, \text{运动}\}$ 等等，重要的是 S 所含的符号个数，通常我们将其记为 $\{0, 1\}$ 。此时，邻居集 N 的个数 $2 \cdot r = 2$ ，局部映射 $f: S_3 \rightarrow S$ 可记为：

$$S_i^{t+1} = f(S_{i-1}^t, S_i^t, S_{i+1}^t)$$




- 初等元胞自动机是状态集 S 只有两个元素 $\{s_1, s_2\}$ ，即状态个数 $k=2$ ，邻居半径 $r=1$ 的一维元胞自动机。由于在 S 中具体采用什么符号并不重要，它可取 $\{0, 1\}$ ， $\{-1, 1\}$ ， $\{\text{静止}, \text{运动}\}$ 等等，重要的是 S 所含的符号个数，通常我们将其记为 $\{0, 1\}$ 。此时，邻居集 N 的个数 $2 \cdot r = 2$ ，局部映射 $f: S_3 \rightarrow S$ 可记为：

$$S_i^{t+1} = f(S_{i-1}^t, S_i^t, S_{i+1}^t)$$



t	111	110	101	100	001	010	001	000
t+1	0	1	0	0	1	1	0	0




由于只有0、1两种状态，
所以函数 f 共有 $2^8=256$ 种状态。

t	111	110	101	100	011	010	001	000	
t+1	0	0	0	0	0	0	0	1	rule 1
	0	0	0	0	0	0	1	0	rule 2
	0	0	0	0	0	0	1	1	rule 3
	0	0	0	0	0	1	0	0	rule 4
	...	...	...	...	...	...	...	...	...
	1	0	1	1	1	0	0	0	rule 184
	...	...	...	...	...	...	...	...	...
	1	1	1	1	1	1	1	0	rule 255
	1	1	1	1	1	1	1	1	rule 256

对给定初值及规则 f ，可通过计算机得到 N 步以后的演化结果

详见:

《A New Kind of Science》




- 三个世纪以前，人们发现建立在数学方程基础上的规律能够用于对自然界的描述，伴随着这种新观念，科学发生了变革。在此书中我的目的是应用简单的计算机程序来表达更为一般的规律，并在此种规律的基础上建立一种新的科学，从而启动另一场科学变革。


Free online access:

<http://www.wolframscience.com/>

90号规则：分形结构



110号规则：复杂结构




更多程序和用法见Mathematica软件及帮助

<https://mathworld.wolfram.com/AdditiveCellularAutomaton.html>

SEE ALSO


[Cellular Automaton](#), [Elementary Cellular Automaton](#), [Commutative Monoid](#), [Finite Field](#), [Modular Arithmetic](#), [Pascal's Triangle](#), [Rule 60](#), [Rule 90](#), [Rule 102](#), [Rule 150](#), [Rule 250](#)

- 一、第184号规则
- 特别注意：第184号规则



特别注意：第184号规则

车辆行驶规则为：黑色元胞表示被一辆车占据，白色表示无车，若前方格子有车，则停止。若前方为空，则前进一格。



t	111	110	101	100	011	010	001	000
t+1	1	0	1	1	1	0	0	0

1992年，德国学者Nagel和Schreckenberg在第184号规则的基础上提出了一维**交通流CA模型**，即，NS 模型（或NaSch模型）

二、NS 模型

- 在第184号规则的基础上，1992年，德国学者Nagel和Schreckenberg提出了一维交通流CA模型，即，NS 模型（或NaSch模型）
- Nagel and Schreckenberg. A Cellular automaton model for freeway traffic . Journal of Physics(France), 1992
- CA模型最基本的组成包括四个部分:元胞(cell)、元胞空间(lattice)、邻域(neighbor)及更新规则(rule)。

- NS模型是一个随机CA交通流模型，每辆车的状态都由它的速度和位置所表示，其状态按照以下演化规则并行更新：
- a) 加速过程： $v_n \rightarrow \min(v_n + 1, v_{\max})$
- b) 安全刹车过程： $v_n \rightarrow \min(v_n, d_n - 1)$
- c) 随机慢化过程： $v_n \rightarrow \max(v_n - 1, 0)$
(以随机慢化概率 p)
- d) 位置更新： $x_n \rightarrow x_n + v_n$

$$d_n = x_{n+1} - x_n - L \quad \text{其中: } L \text{---车辆长度} \sim 7.5\text{m}$$

NS模型的演化规则:

- 1) 加速: 司机总是期望以最大的速度行驶
- 2) 安全刹车: 为避免与前车碰撞
- 3) 随机慢化 (以随机慢化概率 p): 由于不确定因素
 - a) 过度刹车
 - b) 道路条件变化
 - c) 心理因素
 - d) 延迟加速
- 4) 位置更新: 车辆前进

例：设 $v_{\max} = 2$

a) 加速过程

b) 安全刹车过程

c) 随机慢化过程(以随机慢化概率 p)

d) 位置更新

Configuration at time t :



a) Acceleration:




b) Braking:



c) Randomization ($p = 1/3$):



d) Driving (= configuration at time $t + 1$):




- 在NS 模型的基础上，又陆续地提出了一系列一维CA交通模型，如TT、BJH、VDR、FI等模型；
- 双车道CA交通模型：STNS模型
- 机非混合CA模型：CCA模型
- 城市路网CA二维模型：BML、CTM模型

近年国际上出现的一门
新的交叉学科
—交通物理学



B.S.Kerner, Springer 2004




- “幽灵式交通堵塞” (“phantom” or “ghost” traffic jams) 的现象早在1975年就由Treiterer 和 Myers 通过航拍图像发现。
- 直到1992年由德国学者Nagel 和 Schreckenberg 用元胞自动机(CA) 交通流模型才加以成功再现和模拟解释。
- Nagel and Schreckenberg. A Cellular automaton model for freeway traffic . Journal of Physics(France), 1992

条件:


- 随机慢化概率(减速概率) p ;
- 密度 $\rho=13.3\text{veh/km/lan}$ (0.1)
 $\rho=20\text{veh/km/lan}$ (0.15)
 $\rho=33\text{veh/km/lan}$ (0.25)
- 车辆长度 $\sim 7.5\text{m}$; 道路长度 $L=7.5\text{m}\times 120=900\text{m}$
- 速度: $1 \sim 7.5\text{m/s}=27\text{km/h}$;
 $2 \sim 2\times 7.5\text{m/s}=54\text{km/h}$;
 $3 \sim 3\times 7.5\text{m/s}=81\text{km/h}$;
 $4 \sim 4\times 7.5\text{m/s}=108\text{km/h}$;
 $5 \sim 5\times 7.5\text{m/s}=135\text{km/h}$;

[Cellular/main_new.py](#)


交通模拟(车道长度5000, 车辆数100, 初速度60, 减速概率0.3)




交通模拟(车道长度5000, 车辆数200, 初速度60, 减速概率0.3)




交通模拟(车道长度5000, 车辆数300, 初速度60, 减速概率0.3)



交通模拟(车道长度5000, 车辆数500, 初速度60, 减速概率0.3)




交通模拟(车道长度5000, 车辆数400, 初速度60, 减速概率0.3)



- 交通流CA模型的主要优点：
 - (1) 模型简单，特别易于在计算机上实现。
 - (2) 能够再现各种复杂的交通现象，反映交通流特性。在模拟过程中人们通过考察元胞状态的变化，不仅可以得到每一辆车在任意时刻的速度、位移以及车头时距等参数描述交通流的微观特性，还可以得到平均速度、密度、流量等参数，呈现交通流的宏观特性。
 - (3) 能够再现单车道、多车道以及路网的交通流建模；机动车和非机动车交通流的建模

与传统的建模方法相比，元胞自动机直接模拟系统各组元之间的**相互作用**，因此能够通过一些简单的规则产生出高度复杂的演化结果。该方法现在已经成功地运用于对诸如交通系统、经济系统、火灾系统等复杂系统的研究中。



生命游戏背景及逆问题

生命游戏 (game of life) 是由剑桥大学的数学家John Horton Conway在1970年提出来的。



- 1) 个体分布在规则划分的二维矩形网格上；
- 2) 个体具有0, 1两种状态, 0代表“死”, 1代表“生”；
- 3) 个体以相邻的8个个体为邻居；
- 4) 一个个体的生死由其在该时刻本身的生死状态和周围八个邻居的状态决定。

生命游戏规则

- **生存**：对一个活的个体，如果它的邻居中有两个或三个个体是活的，那么该个体将继续生存下去。
- **死亡**：对一个活的个体 (a) 如果它的邻居中有四个或四个以上的个体是活的，那么该个体将死去；(b) 如果它的邻居中只有一个或没有活的个体，那么该个体也将死去。
- **繁殖**：对一个死的个体，如果它的邻居中有3个（不能多也不能少）活的，那么该个体将成为一个活的个体。


生命游戏规则(数学形式)

$$\text{if } S_i^t = 1, \text{ then } S_i^{t+1} = \begin{cases} 1, & \text{if } \sum S_N^t = 2 \text{ or } 3 \\ 0, & \text{if } \sum S_N^t < 2 \text{ or } \sum S_N^t > 3 \end{cases}$$


$$\text{if } S_i^t = 0, \text{ then } S_i^{t+1} = \begin{cases} 1, & \text{if } \sum S_N^t = 3 \\ 0, & \text{if } \sum S_N^t \neq 3 \end{cases}$$

规则的不断演化所形成的规律性与初始状态有关，不同的初始状态可能导致不同的演化结果。


脉冲星 (Explore)



滑翔机 (Glider)



滑翔机发射器 (Gosper Glider Gun)



生命游戏的正问题

若不研究生命游戏本身为什么表现出来的规律性，仅仅关心其一步步迭代优化，正问题是个容易实现和判断的问题，因为只要给定当前状态和规则，下一步的状态一定是确定的和唯一的。

生命游戏的逆问题：

相比正问题，逆问题的难度就大多了。逆问题描述的是：若给定了生命游戏的某一个状态，要确定其上一步是什么状态。这样的问题从数学上来说是有病态的，因为其前一步状态具有不确定性。

生命游戏的逆问题

(1) 对于生命游戏，能否由当前的进化状态推测出其以前的状态？请建立回溯模型或算法，来推测当前游戏状态往前回溯 δ (≤ 5) 步的初始状态。要求建立模型求出它们往前回溯 δ 步的初始状态。需要注意的是，初始状态可能不唯一，求出其中之一即可。

作

(2) 为进一步考虑，能否给出回溯1步有唯一结果所要求满足的条件？测试数据集中有哪些游戏的回溯初始状态是唯一的？

问题的难点

- (1) 正问题是一个线性问题，但逆问题向前一个状态推导是高度非线性性的问题；
- (2) 规模大：20*20的棋盘涉及到的变量有 2^{400} ，难以求解；
- (3) 前一状态的不确定性大，难以找到一个有效的、有序的推测前一个状态的方法。

生命游戏逆问题的数学模型

下面针对一步回溯状态来建立模型：

根据生命游戏的规则，写成数学表达式为

$$\text{if } S_i^t = 1, \text{ then } S_i^{t+1} = \begin{cases} 1, & \text{if } \sum S_N^t = 2 \text{ or } 3 \\ 0, & \text{if } \sum S_N^t < 2 \text{ or } \sum S_N^t > 3 \end{cases}$$

$$\text{if } S_i^t = 0, \text{ then } S_i^{t+1} = \begin{cases} 1, & \text{if } \sum S_N^t = 3 \\ 0, & \text{if } \sum S_N^t \neq 3 \end{cases}$$

其中 $N(i,j)$ 表示位置 (i,j) 的8邻域。将上述规则依次命名为规则1-规则4。

生命游戏的逆问题模型可表达为：

设 X, Y 为0-1矩阵，分别表示游戏的一步初态和终态，并设 $B(X)$ 为对 X 的加窗（窗口大小3*3）求和操作，即。

$$Z = B(X)$$

$$Z_{ij} = \sum_{k=-1}^1 \sum_{t=-1}^1 x_{i+k, j+t} - x_{ij}$$

生命游戏及其逆问题的模型可表达为

$$F(B(X)) = Y$$

其中 F 函数由生命游戏规则所确定，逆问题描述为已知 Y 求 X ， F 函数及 B 操作反函数的非线性，导致问题求解难度大。

基本模型

设:

$y_{ij} (i, j = 1, 2, \dots, 20)$ 表示当前终局状态;

$x_{ij} (i, j = 1, 2, \dots, 20)$ 表示其一步回溯状态;

$w_{ij} (i, j = 1, 2, \dots, 20)$ 表示个体 (i, j) 周围8邻居中活个体的个数, 即

$$w_{ij} = \sum_{k=-1}^1 \sum_{t=-1}^1 x_{i+k, j+t} - x_{ij}$$

基本模型

则对于 $\forall i, j$ 变量 x_{ij} 和 y_{ij} 满足下面方程:

$$(w_{ij} - 2)^{x_{ij}}(w_{ij} - 3) = 0, \text{if } y_{ij} = 1 \quad (1)$$

$$(w_{ij} - 2)^{x_{ij}}(w_{ij} - 3) \neq 0, \text{if } y_{ij} = 0 \quad (2)$$

这里假设0的0次方为1，这个量在数学中没有明确定义，不同软件对其计算不一样，比如matlab计算 $0^0=1$ ，但Lingo则认为 $0^0=0$ 。若用lingo解上述方程，则需要将方程进行转换为如下形式，否则不正确。

$$(w_{ij} - 2 + x_{ij} - 1)^{x_{ij}}(w_{ij} - 3) = 0, \text{if } y_{ij} = 1 \quad (3)$$

$$(w_{ij} - 2 + x_{ij} - 1)^{x_{ij}}(w_{ij} - 3) \neq 0, \text{if } y_{ij} = 0 \quad (4)$$

基本模型

下面解释方程 (1) 和 (2)

对于方程 (1) :

$$(w_{ij} - 2)^{x_{ij}} (w_{ij} - 3) = 0, \text{ if } y_{ij} = 1$$

要使得方程 (1) 满足, 则必满足:

$$(w_{ij} - 2)^{x_{ij}} = 0 \quad \text{or} \quad (w_{ij} - 3) = 0$$

- 若 $x_{ij}=1$, 则满足上述条件, 即为 $w_{ij}=2$ 或 $w_{ij}=3$, 此对应生命游戏规则1
- 若 $x_{ij}=0$, 则满足上述条件, 即为 $w_{ij}=3$, 此对应生命游戏规则3。

基本模型

对于方程 (2) :

$$(w_{ij} - 2)^{x_{ij}} (w_{ij} - 3) \neq 0, \text{ if } y_{ij} = 0$$

要使得方程 (2) 满足, 则必满足:

$$(w_{ij} - 2)^{x_{ij}} \neq 0 \quad \text{and} \quad (w_{ij} - 3) \neq 0$$

- 若 $x_{ij}=1$, 则满足上述条件, 即为 $w_{ij} \neq 2$ 且 $w_{ij} \neq 3$, 其等价于 $w_{ij} < 2$ 或 $w_{ij} > 3$ 此对应生命游戏规则2
- 若 $x_{ij}=0$, 则满足上述条件, 即为 $w_{ij} \neq 3$, 此对应生命游戏规则3。

基本模型

所以要寻找当前状态的一步回溯状态 $x_{ij}(i,j=1,2,\dots,20)$, 即根据当前状态 $y_{ij}(i,j=1,2,\dots,20)$ 来建立上述相应的方程(1)和(2)。共可以建立400个方程, 且这些方程都是非线性方程。方程存在多个解由两个方面决定:

- 方程本身的非线性导致多解;
- 方程(2)本身为不等式方程, 其满足不等式条件的方程实际上是一族方程构成, 即若设

$$z_{ij} = (w_{ij} - 2)^{x_{ij}} (w_{ij} - 3)$$

即 z_{ij} 可以根据 w_{ij} 和 x_{ij} 的值决定可能取的一系列值。

问题求解 可以用lingo软件解上述方程

```

Model:
Sets:
Size/1..22/;;
Var(Size,Size): y,w,x;
temp/1..3/;;
link(temp,temp);
EndSets
Data:
y = ; !输入矩阵;

EndData
!Min = @sum(Var(i,j)|i#ge#2 #and# i#le#21 #and# j#ge#2 #and# j#le#21:x(i,j));
@for(Var(i,j)|i#ge#2 #and# i#le#21 #and# j#ge#2 #and# j#le#21: w(i,j)= x(i-1,j-1)+x(i-1,j)+x(i-1,j+1)+
x(i,j-1)+x(i,j+1)+x(i+1,j-1)+x(i+1,j)+x(i+1,j+1));
@for(Var(i,j)|i#ge#2 #and# i#le#21 #and# j#ge#2 #and# j#le#21 #and# y(i,j)#eq#1:(w(i,j)-2+x(i,j)-1)^x(i,j)*(w(i,j)-3)=0);
@for(Var(i,j)|i#ge#2 #and# i#le#21 #and# j#ge#2 #and# j#le#21 #and# y(i,j)#eq#0:@ABS((w(i,j)-2+x(i,j)-1)^x(i,j)*(w(i,j)-3))>0.1);
@for(Var(i,j)|i#eq#1 #or# i#eq#22 #or# j#eq#1 #or# j#eq#22:x(i,j) = 0);
@for(Var(i,j)|i#ge#8 #and# i#le#21: x(i,j) = 0);
@for(Var(i,j)|j#ge#8 #and# j#le#21: x(i,j) = 0);
@for(Var(i,j):@bin(x(i,j)));
End



```

LINGO代码

Python代码

[GAME_OF_LIFE/GameOfLife.py](#)

数据终态（3）及其一步回溯求解结果：



求解碰到的问题：

- (1) 求到的解只是众多解中的某一个，对于解没有给出任何其它约束；
- (2) 问题规模太大，求解效果极低下。

优化模型

考虑到基本方程的多解性以及计算量大，可将问题进一步约束来从方程组的多解中获得满足某些特殊要求的解，比如活细胞最小的解就是一个非常重要的约束，即考虑优化问题：

$$\min F = \min \sum_{i=1}^{20} \sum_{j=1}^{20} x_{ij}$$

满足



$$(w_{ij} - 2)^{x_{ij}} (w_{ij} - 3) = 0, \text{ if } y_{ij} = 1, i, j = 1, 2, \dots, 20$$

$$(w_{ij} - 2)^{x_{ij}} (w_{ij} - 3) \neq 0, \text{ if } y_{ij} = 0, i, j = 1, 2, \dots, 20$$

$$x_{ij} = 0 \text{ or } 1, \text{ for } \forall i, j = 1, 2, \dots, 20$$

优化模型

该优化问题即是要求终局的一步回溯状态使得这个状态中活的细胞最少，数据3的求解结果。



该模型的计算效率仍然较低，但从上述结果容易看到，事实上在上面右图中的“死”细胞处还可扩展出大量的结果，只要这些细胞在一步中消失。也就是说该结果给出了某种问题的基本解。

优化模型

该优化模型是非常重要的模型，在此基础上，容易猜想一个问题问题：对于终态的一步回朔，是否存在一些最核心的细胞，这些细胞的状态一定是确定的，否则难以进化到终态，这种情况称之为“基解”。其它的解都是在这个解基础上可扩展。

上述优化模型所确立的最小“活”细胞的解是否是终态的“基解”？直观感觉，最小“活”细胞的解是“基解”，但不见得基解唯一，也许还存在“活”细胞数量一样，但同样是一步回朔解的情况，那么这就形成了基解唯一性问题以及找出所有基解的问题。

优化模型

当然，约束条件还可以采用其他约束，比如：

- 活细胞最多；
- 活细胞分布最集中（紧凑）或最分散；
-

另外就是也可以考虑添加约束条件来限制解，但添加约束条件最佳的还是降低计算复杂度，如限定一步回朔的活细胞范围。

优化模型

$$\min F = \min \sum_{i=1}^{20} \sum_{j=1}^{20} x_{ij}$$

满足

$$(w_{ij} - 2)^{x_{ij}} (w_{ij} - 3) = 0, \text{ if } y_{ij} = 1, i, j = 1, 2, \dots, 20$$

$$(w_{ij} - 2)^{x_{ij}} (w_{ij} - 3) \neq 0, \text{ if } y_{ij} = 0, i, j = 1, 2, \dots, 20$$

$$x_{ij} = 0 \text{ or } 1, \text{ for } \forall i, j = 1, 2, \dots, 20$$

$$x_{ij} = 0, \text{ if } i < lu \text{ or } i > ld$$

$$x_{ij} = 0, \text{ if } j < lf \text{ or } j > lr$$

优化模型

增加约束限制活细胞分布范围最大的好处是极大的加快的模型的计算：



不增加约束范围的全区域优化时间长达1-2小时，添加活细胞分布范围后，计算减少为几分钟，这就使得对于回朔状态的求解具有了可行性。

当然，也会出现新的问题：如何限制范围，甚至是找到最小的范围限制。

基于非线性规划模型的遗传算法求解

考虑到本问题的大规模和高度非线性，也可考虑采用遗传算法等方法求解，比如建立如下模型：

$$\min F = \min \sum_{ij} (y_{ij} \oplus a_{ij})$$

满足

$$a_{ij} = 1, \text{ if } x_{ij} = 1 \text{ and } (w_{ij} = 2 \text{ or } w_{ij} = 3) \quad i, j = 1, 2, \dots, 20$$

$$a_{ij} = 1, \text{ if } x_{ij} = 0 \text{ and } (w_{ij} = 3) \quad i, j = 1, 2, \dots, 20$$

$$a_{ij} = 0, \text{ if } x_{ij} = 0 \text{ and } (w_{ij} < 2 \text{ or } w_{ij} > 3) \quad i, j = 1, 2, \dots, 20$$

$$a_{ij} = 0, \text{ if } x_{ij} = 1 \text{ and } (w_{ij} \neq 3) \quad i, j = 1, 2, \dots, 20$$

$$x_{ij} = 0 \text{ or } 1$$

[gameoflife_nonlinear.py](#)

基于非线性规划模型的遗传算法求解

该模型的利用常规优化方法求解难度很大（高度非线性，局部极值点多），采用遗传算法求解不失为一个有效的方法：

基于非线性规划模型的遗传算法求解

采用遗传算法对该问题进行求解，有优点也有缺点：

优点：

- 求解速度要快于前面建立的优化模型；
- 一旦找到最优解，往往一次能得到多个最优解；

缺点：

- 不容易找到最优解，往往要运行多次才能找到一个。

进一步扩展和研究

生命游戏的逆问题仍然留有不少问题可进一步研究：

- (1) 目标与约束的提出，若考虑前面提的“基解”问题，则其存在性和唯一性等研究；
- (2) 解约束范围的限定，如何找到最有效的约束范围；
- (3) 对于给定的终态，其一步回溯的所有解中是否存在某些特殊的位置一定必须保持是活细胞才能获得该终态；
- (4) 如何更加有效的提高计算效率。

➤ 以下情况可考虑计算机仿真：

1. 难以用数学公式表示的系统,或者没有建立和求解的有效方法.
2. 虽然可以用解析的方法解决问题,但数学的分析与计算过于复杂,这时计算机仿真可能提供简单可行的求解方法.
3. 希望能在较短的时间内观察到系统发展的全过程,以估计某些参数对系统行为的影响.
4. 难以在实际环境中进行试验和观察时,计算机仿真是唯一可行的方法,如太空飞行的研究.
5. 需要对系统或过程进行长期运行比较,从大量方案中寻找最优方案.




深度学习算法




学习目标


- ◆ 了解人脑神经元的结构及特点，熟悉人工神经元模型。
- ◆ 掌握感知机的基本原理，熟悉前馈神经网络的特征以及反向传播的思想。
- ◆ 熟悉Sigmoid、Tanh、ReLU、LReLU等激活函数的特点及应用。
- ◆ 熟悉卷积神经网络的基本结构以及局部连接和权重共享等特点，掌握卷积、池化操作。
- ◆ 熟悉LSTM中的输入门、遗忘门和输出门的工作机制和作用。
- ◆ 掌握生成式对抗网络的基本原理，熟悉生成器和判别器的作用。
- ◆ 了解原始GAN的优缺点以及各种衍生模型的特点及应用。

传统机器学习



深度学习





■ 人工神经网络发展史（第一阶段）

- 1943年, McCulloch和Pitts 提出第一个神经元数学模型, 即**M-P模型**, 并从原理上证明了人工神经网络能够计算任何算数和逻辑函数。
- 1949年, Hebb 发表《The Organization of Behavior》一书, 提出生物神经元学习的机理, 即**Hebb学习规则**。
- 1958年, Rosenblatt 提出**感知机** (Perceptron) 模型和其学习规则。
- 1960年, Widrow和Hoff提出**自适应线性神经元** (Adaline) 模型和**最小均方学习算法**。
- 1969年, Minsky和Papert 发表《Perceptrons》一书, 指出**单层神经网络不能解决非线性问题, 多层网络的训练算法尚无希望**。这个论断导致神经网络进入低谷。

■ 人工神经网络发展史（第二阶段）

- 1982年, 物理学家Hopfield提出了一种具有联想记忆、优化计算能力的递归网络模型, 即Hopfield网络。
- 1986年, Rumelhart 等编辑的著作《Parallel Distributed Processing: Explorations in the Microstructures of Cognition》报告了反向传播算法
- 1987年, IEEE在美国加州圣地亚哥召开第一届神经网络国际会议 (ICNN) 。
- 1990年代初, 伴随统计学习理论和SVM的兴起, 神经网络由于理论不够清楚, 试错性强, 难以训练, 再次进入低谷。

■ 人工神经网络发展史（第三阶段）

- 2006年, Hinton提出了深度信念网络(DBN), 通过 “预训练+微调” 使得深度学习模型的最优化变得相对容易。
- 2012年, Hinton 组参加ImageNet 竞赛, 使用 CNN 模型以超过第二名10个百分点的成绩夺得当年竞赛的冠军。
- 伴随云计算、大数据时代的到来, 计算能力的大幅提升, 使得深度学习模型在计算机视觉、自然语言处理、语音识别等众多领域都取得了较大的成功。


Images & Video




Text & Language



Speech & Audio



■ 人脑神经元结构及其特点




- **人工神经元模型**的建立来源于**生物神经元结构**的仿生模拟，用来模拟人工神经网络。
- 人们提出的神经元模型有很多，其中最早提出并且影响较大的是由心理学家 W. McCulloch 和数学家 W. Pitts 于1943年提出的模型。该模型称为**McCulloch-Pitts神经元模型**，简称MCP 神经元模型。
- MCP 神经元以人脑神经元为原型，受到了其激活机制的启发和影响。
- MCP 神经元模型经过不断改进后，形成现在广泛应用的**BP神经元模型**。

■ 人工神经元模型

- 一个简单的人工神经元模型可以表示为


$$y = \begin{cases} 1, & w^T x + b > 0 \\ 0, & w^T x + b \leq 0 \end{cases}$$

- 一个典型的人工神经元的模型:







■ 感知机

- 1958年, Rosenblatt 提出了由两层神经元组成的神经网络, 称为感知机 (Perceptron)
- 输入层接受外界输入信号传递给输出层, 输出层是MCP神经元 (阈值逻辑单元)
- 感知机能够容易地实现逻辑 “与” 、 “或” 、 “非” 运算





■ 单层感知机的局限性

- 单层感知机只有输出层神经元进行激活函数处理，即只有一层功能神经元，学习能力非常有限，只能解决线性可分问题。
- 可以求解线性可分的逻辑“与”、“或”、“非”问题，不能求解线性不可分的“异或”问题。




■ 解决异或问题的多层感知机




- 输出层与输入层之间的一层神经元，被称之为**隐层或隐含层**，隐含层和输出层神经元都是具有激活函数的功能神经元。

■ 前馈神经网络

- 前馈神经网络（FNN）是一种**单向的多层感知机**，即信息是从输入层开始，逐层向一个方向传递，一直到输出层结束。
- 所谓的“前馈”是指输入信号的传播方向为前向，在此过程中并不调整各层神经元连接的权值参数。
- 反向传播时是将误差逐层向后传递，通过**反向传播（BP）**方法来调整各层网络中神经元之间连接的权重参数。



(a) 单隐层前馈网络



(b) 双隐层前馈网络

■ 前馈神经网络

- **前向传播过程**：输入已知学习样本，通过设置的网络结构和前一次迭代的权值和阈值，从网络的第一层向后计算各神经元输出。
- **反向传播过程**：反向传播时，对权值和阈值进行修改：从最后一层向前计算各权值和阈值对总误差的影响（梯度），据此对各权值和阈值进行修改。

以上两个过程反复交替，直到达到收敛为止！


■ 前馈神经网络

由于误差逐层往回传递，以修正层与层间的权值和阈值，所以称该算法为**误差反向传播**（Back Propagation, BP）算法，这种误差反传学习算法可以推广到有若干个中间层的多层网络，因此该多层网络常称之为 BP 网络。标准的BP算法，其权值的修正是沿着误差性能函数梯度的反方向进行的。

■ 神经网络的激活函数


- 激活函数模拟了人脑神经元特性：接受一组输入信号并产生输出。
- 理想的激活函数是阶跃函数，0表示抑制神经元，1表示激活神经元。
- 阶跃函数具有不连续、不光滑等不好的性质。

下面介绍几种较有代表性的激活函数。



(a) 阶跃函数

- 神经网络的激活函数
- Sigmoid 函数: Sigmoid 函数也称为Logistic函数




$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

■ 神经网络的激活函数

■ Tanh 函数：Tanh 函数是双曲正切函数，其数学表达式为


$$f_{\text{Tanh}}(x) = \frac{\sinh(x)}{\cosh(x)} = \frac{e^x - e^{-x}}{e^x + e^{-x}} = \frac{2}{1 + e^{-2x}} - 1$$




■ 神经网络的激活函数

- ReLU 函数：修正线性单元（Rectified Linear Unit, ReLU）函数，又称整流线性单元或线性整流函数。

$$f_{\text{ReLU}}(x) = \begin{cases} x, & x > 0 \\ 0, & x \leq 0 \end{cases}$$
$$= \max(0, x)$$



ReLU函数




ReLU函数的导数

■ 神经网络的激活函数

■ Leak ReLU 函数：带泄露的修正线性单元 (LReLU) 函数

$$f_{\text{LReLU}}(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases}$$



LReLU函数

相同点:

二者均采用分层结构，系统包括输入层，隐藏层（多层），输出层组成的多层网络，只有相邻层节点之间有连接，同一层以及跨层节点之间相互无连接，每一层都可以看作是一个logistic回归模型。

不同点:

(1) 神经网络:

(a) 采用BP算法调整参数，即采用迭代式算法来训练整个网络。随机设定初值，计算当前网络的输出，然后根据当前输出和样本真实标签之间的差去改变前面各层的参数，直到收敛；

(b) 比较容易过拟合，参数比较难调整，而且需要不少的技巧。

(c) 训练速度比较慢。在成熟比较少（小于等于3）的情况下效果并不比其他方法更优；


(2) 深度学习：采用逐层训练机制。采用该机制的原因在于如果采用BP机制，对于一个深层网络（7层以上），残差传播到最前面的层将变得很小，出现所谓的gradient diffusion（梯度扩散）。

■ 引言

- 卷积神经网络(CNN)是一种具有局部连接、权重共享等特性的前馈神经网络。
- 20世纪80 年代中期日本学者福岛邦彦等提出的“神经认知机” (Neocognition) 模型，是第一个基于神经元之间的局部连接性和层次结构组织的人工神经网络，可以被视为卷积神经网络的雏形。
- 1989年，YannLeCun等对权重进行随机初始化后使用了反向传播算法对网络进行训练，并首次使用了“卷积”一词，将卷积神经网络成功应用到美国邮局的手写字符识别系统中。
- 1998年，YannLeCun等人在之前卷积神经网络的基础上构建了经典的卷积神经网络模型LeNet-5，并再次提高手写字符识别的准确率。
- 2006年逐层训练参数与预训练方法使得卷积神经网络可以设计得更复杂，训练效果更好。

■ 视觉皮层的工作机理

- ✓ 1981 年的诺贝尔医学奖，颁发给了 David Hubel、Torsten Wiesel以及 Roger Sperry。
- ✓ 前两位的主要贡献是 “发现了视觉系统的信息处理机制”：视觉皮层是分级的。





人脑中有150多亿个神经元

■ 视觉皮层的工作机理


- ✓ 上述发现激发了人们对于神经系统的进一步思考。神经-中枢-大脑的工作过程，或许是一个不断迭代、不断抽象的过程。
- ✓ 人类的逻辑思维，经常使用高度抽象的概念。从原始信号做低级抽象，逐渐向高级抽象迭代。
- ✓ 人的视觉系统的信息处理是分级的。从V1区提取低级的边缘特征，再到V2区提取形状或者目标的部分等，再到更高层，整个目标、目标的行为等。
- ✓ 这个发现促成了计算机人工智能在40年后的突破性发展。

■ 视觉皮层的工作机理




■ 卷积神经网络的基本结构

- ✓ CNN依旧是层级网络
- ✓ 但层的功能和形式做了变化



卷积神经网络的基本结构



- ✓ 数据输入层/ Input layer
- ✓ 卷积层/ CONV layer
- ✓ ReLU激励层 / ReLU layer
- ✓ 池化层 / Pooling layer
- ✓ 全连接层 / FC layer

■ 卷积神经网络的基本结构

■ 数据输入层/ Input layer

有3种常见的图像数据处理方式

● 去均值

□ 把输入数据各个维度都中心化到0

● 归一化

□ 幅度归一化到同样的范围

● PCA/白话


□ 用PCA降维

□ 白化是对数据每个特征轴上的幅度归一化

■ 卷积神经网络的基本结构


• 卷积层/ CONV layer

- 局部关联，每个神经元看做一个filter。
- 窗口(receptive field, 局部感受野)滑动， filter对局部数据计算
- 权值共享机制，即每个神经元连接数据窗的权重是固定的
- 固定每个神经元连接权重， 可以看做模板
- 需要估算的权重个数减少: AlexNet 1亿 $\Rightarrow$ 3.5w
- 一组固定的权重和不同窗口内数据做内积: 卷积




■ 卷积神经网络的基本结构

• 卷积层/ CONV layer




$$Y = \text{conv}(X, W, \text{valid})$$




卷积神经网络的基本结构

卷积层操作



二维卷积运算示意图



卷积运算与互相关系运算之间的差异
a) 卷积运算 b) 互相关系运算

■ 卷积神经网络的基本结构

- 激励层 / ReLU layer
- 把卷积层输出结果做非线性映射
 - Sigmoid
 - Tanh(双曲正切)
 - ReLU (The Rectified Linear Unit, 修正线性单元)
 - Leaky ReLU
 - ELU
 - Maxout

■ 卷积神经网络的基本结构


• 激励层 / ReLU layer



■ 卷积神经网络的基本结构

• 池化层 / Pooling layer

- 位于相邻的卷积层中间
- 压缩数据和参数的量, **特征降维**



■ 卷积神经网络的基本结构

• 池化层 / Pooling layer

3	2	5	3
1	4	2	2
2	1	4	3
1	3	5	0

最大值池化



4	5
3	5

3	2	5	3
1	4	2	2
2	0	4	3
1	3	5	0


均值池化



2.5	3
1.5	3

■ 卷积神经网络的基本结构

- 全连接层 / FC layer
 - 两层之间所有神经元都有权重连接
 - 通常全连接层位于卷积神经网络尾部





卷积神经网络避免了显式的特征取样，隐式地从训练数据中进行学习。这使得卷积神经网络明显有别于其他基于神经网络的分类器，通过结构重组和减少权值将特征提取功能融合进多层感知器。它可以直接处理灰度图片，能够直接用于处理基于图像的分类。

[CNN/main.py](#)

卷积神经网络较一般神经网络在图像处理方面有如下**优点**:

- a)输入图像和网络的拓扑结构能很好的吻合;
- b)特征提取和模式分类同时进行，并同时在训练中产生;
- c)权重共享可以减少网络的训练参数，使神经网络结构变得更简单，适应性更强


基本的循环神经网络结构




按时间序列展开的单隐藏层单向RNN结构

[RNN/main.py](#)

长短时记忆神经网络结构





LSTM的单元格 (Cell) 结构




RNN简化模型


长短时记忆神经网络结构



长短时记忆神经网络结构



LSTM中门的结构




遗忘门结构

长短时记忆神经网络结构


$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$




输入门结构

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$$




更新单元格状态

长短时记忆神经网络结构



生成式对抗网络基本原理



生成式对抗网络（GAN, Generative Adversarial Networks）是一种[深度学习模型](#)，是近年来复杂分布上[无监督学习](#)最具前景的方法之一。模型通过框架中（至少）两个模块：[生成模型](#)（Generative Model）和[判别模型](#)（Discriminative Model）的互相博弈学习产生相当好的输出。原始 GAN [理论](#)中，并不要求 G 和 D 都是神经网络，只需要是能拟合相应生成和判别的函数即可。但实用中一般均使用深度神经网络作为 G 和 D。一个优秀的GAN应用需要有良好的训练方法，否则可能由于[神经网络模型](#)的自由性而导致输出不理想。



GAN工作原理框图


生成式对抗网络基本原理

$$\min_G \max_D V(D, G) = \min_G \max_D \left(E_{x \sim p_{\text{data}}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))] \right)$$

(a) D 的优化过程(b) G 的优化过程

GAN训练过程的参数优化示意图


生成式对抗网络基本原理



$$\min_G \max_D V(D, G) = \min_G \max_D \left(E_{x \sim p_{\text{data}}(x)} [\log D(x|y)] + E_{z \sim p_z(z)} [\log (1 - D(G(z|y)|y))] \right)$$

条件生成式对抗网络模型示意图


条件生成式对抗网络



$$\min_G \max_D V(D, G) = \min_G \max_D \left(E_{x \sim p_{\text{data}}(x)} [\log D(x|y)] + E_{z \sim p_z(z)} [\log (1 - D(G(z|y)|y))] \right)$$


条件生成式对抗网络模型示意图

深度卷积生成式对抗网络



DCGAN生成器结构示意图

深度卷积生成式对抗网络



DCGAN判别器结构示意图

- ◆ 深度学习通过学习一种深层非线性网络结构，只需简单的网络结构即可实现复杂函数的逼近，并展现了强大的从大量无标注样本集中学习数据集本质特征的能力。
- ◆ 深度学习能够获得可更好地表示数据的特征，同时由于模型的层次深）、表达能力强，因此有能力表示大规模数据。
- ◆ 对于图像、语音这种特征不明显（需要手工设计且很多没有直观的物理含义）的问题，深度模型能够在大规模训练数据上取得更好的效果。

- ◆ 卷积神经网络(Convolutional Neural Networks: CNN)是人工神经网络(ANN)的一种，是深度学习的一种学习算法。它在图像识别和分类、自然语言处理、广告系统中都有应用。
- ◆ CNNs它利用空间关系减少需要学习的参数数目，以提高一般前向BP算法的训练性能。CNNs作为一个深度学习架构提出是为了最小化数据的预处理要求。在CNN中，图像的一小部分（局部感受区域）作为层级结构的最低层的输入，信息再依次传输到不同的层，每层通过一个数字滤波器去获得观测数据的最显著的特征。这个方法能够获取对平移、缩放和旋转不变的观测数据的显著特征，因为图像的局部感受区域允许神经元或者处理单元可以访问到最基础的特征，例如定向边缘。




数学建模真题



问题背景

目前常用WRF-CMAQ模拟体系（以下简称WRF-CMAQ模型）对空气质量进行预报。WRF-CMAQ模型主要包括WRF和CMAQ两部分：WRF是一种中尺度数值天气预报系统，用于为CMAQ提供所需的气象场数据；CMAQ是一种三维欧拉大气化学与传输模拟系统，其根据来自WRF的气象信息及场域内的污染排放清单，基于物理和化学反应原理模拟污染物等的变化过程，继而得到具体时间点或时间段的预报结果。

但受制于模拟的气象场以及排放清单的不确定性，以及对包括臭氧在内的污染物生成机理的不完全明晰，WRF-CMAQ预报模型的结果并不理想。故题目提出二次建模概念：即指在WRF-CMAQ等一次预报模型模拟结果的基础上，结合更多的数据源进行再建模，以提高预报的准确性。



二次模型优化的WRF-CMAQ空气质量预报过程

数据支撑及说明

为进行二次建模以预测给定监测点未来三天的空气质量情况，题目提供了监测点长期空气质量预报基础数据，包括污染物浓度一次预报数据、气象一次预报数据、气象实测数据和污染物浓度实测数据，其中，所有一次预报数据的时间跨度为2020-7-23 ~ 2021-7-13，所有实测数据的时间跨度为2019-4-16 ~ 2021-7-13，数据总量在十万量级。需要注意的是：

- (1) 每日预报的时间固定为早晨7点，此时可以获得当日7时及之前时刻的实测数据，以及运行日期在当日及之前日期的一次预报数据（预报时间范围截至第三日23时）。监测时间在当日7时以后的逐小时实测数据和运行日期在次日及以后的一次预报数据都是无法获得的，例如：在2021年7月13日晨间对7月13日至7月15日的空气质量进行预报过程中，可供参考的实测数据时间范围为(2019-04-16 00:00, 2021-07-13 07:00)，模型运行日期范围为(2020-07-23, 2021-07-13)。
- (2) 受监测数据权限及相应监测设备功能等的限制，部分气象指标的实测数据无法获得。
- (3) 由于一次预报对邻近日期的准确度较高，故理论上二次预报对邻近日期的准确度也较高。

问题提出

问题1: 使用附件1中的数据, 按照附录中的方法计算监测点A从2020年8月25日到8月28日每天实测的AQI和首要污染物。AQI计算公式如下


$$IAQI_P = \frac{IAQI_{Hi} - IAQI_{Lo}}{BP_{Hi} - BP_{Lo}} \cdot (C_P - BP_{Lo}) + IAQI_{Lo}$$

问题2: 在污染物排放情况不变的条件下, 某一地区的气象条件有利于污染物扩散或沉降时, 该地区的AQI会下降, 反之会上升。使用附件1中的数据, 根据对污染物浓度的影响程度, 对气象条件进行合理分类, 并阐述各类气象条件的特征。

问题3: 使用附件1、2中的数据, 建立一个同时适用于A、B、C三个监测点(监测点两两间直线距离>100km, 忽略相互影响)的二次预报数学模型, 用来预测未来三天6种常规污染物单日浓度值, 要求二次预报模型预测结果中AQI预报值的最大相对误差应尽量小, 且首要污染物预测准确度尽量高。并使用该模型预测监测点A、B、C在2021年7月13日至7月15日6种常规污染物的单日浓度值, 计算相应的AQI和首要污染物, 将结果依照附录“污染物浓度及AQI预测结果表”的格式放在论文中。

问题提出

问题4：相邻区域的污染物浓度往往具有一定的相关性，区域协同预报可能会提升空气质量预报的准确度。如图4，监测点A的临近区域内存在监测点A1、A2、A3，使用附件1、3中的数据，建立包含A、A1、A2、A3四个监测点的协同预报模型，要求二次模型预测结果中AQI预报值的最大相对误差应尽量小，且首要污染物预测准确度尽量高。使用该模型预测监测点A、A1、A2、A3在2021年7月13日至7月15日6种常规污染物的单日浓度值，计算相应的AQI和首要污染物，将结果依照附录“污染物浓度及AQI预测结果表”的格式放在论文中。并讨论：与问题3的模型相比，协同预报模型能否提升针对监测点A的污染物浓度预报准确度？说明原因。



问题一

问题1: 使用附件1中的数据, 按照附录中的方法计算监测点A从2020年8月25日到8月28日每天实测的AQI和首要污染物。AQI计算公式如下

$$IAQI_p = \frac{IAQI_{Hi} - IAQI_{Lo}}{BP_{Hi} - BP_{Lo}} \cdot (C_p - BP_{Lo}) + IAQI_{Lo}$$

【解题思路】 直接根据公式进行计算 (简单考察了数据处理的能力)

问题二

空气质量在很大程度上受到气象因素的影响。在其他因素保持恒定的情况下，不同气象条件会影响污染物的浓度，进而作用于空气质量。**问题二**要求分析提供的数据，根据其中污染物浓度与气象数据之间的关系，**将气象条件划分为不同类型，并阐述各类型所具备的特征。**

【解题思路】初步判断本题为分类问题。通览数据，分类对象应为气象信息，但最终目标是根据这些分类判断不同类型气象对空气质量的影响情况，由于相关气象特征存在量纲不同、种类较多、数据密度不均等现象，因此，需有针对性地对不同气象数据采用预处理办法、主成分分析以及指定聚类所用的样本间似然函数。

数据预处理

首先，对监测点 A 的预报基础数据进行分析，数据情况如下

逐小时污染物浓度与气象一次预报数据	地 2 米温度、地表温度、比湿、湿度、近地 10 米风速、近地 10 米风向等 15 种气象指标和 6 种常规污染物共 21 种特征
逐小时污染物浓度与气象实测数据	包含 6 项常规污染物监测浓度及温度、湿度、气压、风速、风向共 11 种特征，
逐日污染物浓度实测数据	6 种常规污染物的逐日监测数据

异常值：舍弃

缺失值：若缺失数据为输入集，如存在整日数据缺失则成对地排除样本，即在标签集中舍弃对应日期数据；其他情况则忽略缺失；若缺失数据为标签集，进行分段归一化处理时跳过缺失样本，并且在后续回归、相关性分析时排除这些样本


分段归一化：根据《空气污染气象学教程》将污染物扩散条件划分为3个等级进行min-max标准化

注意：风向在实际中不应具有大小顺序，因此对风向指标进行伪独热码处理

主要步骤

- SVD 主成分分析以及 Spearman 相关性分析进行气象指标的降维和筛选;


拟先对输入集每项气象内部 24小时值采用奇异值分解算法 (SVD) 进行主成分分析, 并结合相关性分析筛选出相关性较高的输入集主成分, 其中, 提取小时值主成分后, 由于经预处理处理后 9 风向指标具有一定的离散性, 故使用 Spearman 相关性分析标签集中四种变化较大的污染物扩散条件指数与各气象成分的相关性



主要步骤

- 两步聚类法完成对气象主成分进行分类，并结合污染物扩散条件评价指数频率分布得到不同类型天气的特征

通过主成分分析进行数据降维后，气象数据仍至少含 4 个维度，可视化性低，因而较难初步确定分类个数，故采用两步聚类（Two Step Clustering）算法对气象进行分类。



问题三

问题三要求建立模型用以预测未来三天 6 种常规污染物单日浓度值，并使相应的 AQI 预测结果误差尽量小，首要污染物预测准确度尽量高。根据 AQI 计算方法可知，若 6 种常规污染物的预测准确度不断提高，相应的 AQI 和首要污染物预测效果也会更好。故在问题 3 (及问题 4) 建模过程中，**优先考虑如何提高 6 项常规污染物的预测准确度**。


在模型选择上，大量文献表明**实测数据具有较强时序性**，因此需选用能处理时序问题的模型，同时对比不同模型在不同污染物上的表现力，选择最优模型进行对污染物进行预报。

问题三主要思路

- **特征选择:** 基于随机森林平均不纯度减少的重要度评价方法对特征进行排序
- **模型选择:** 比较前馈神经网络、随机森林、支持向量回归和极端梯度提升树对不同污染物的预报效果，对不同的污染物选择不同的模型进行预测
- **模型组合:** 比较前馈神经网络（FNN）、随机森林（RF）、支持向量回归（SVR）以及极端梯度提升树（XGBoost）、CEEMDAN_IPSOSE_SVR、Lasso 回归与LSTM_FC 的组合模型，并选取最后一种组合模型作为最终空气质量二次建模预报模型

问题三

当前广泛应用的空气质量预测二次建模方法有前馈神经网络、随机森林、支持向量回归和极端梯度提升树等，因此使用这 4 种方法分别进行建模，后进行模型择优等处理




①相对于 WRF-CMAQ，4 种二次预报模型的预测效果均出现提升；

②4 种二次预报模型在不同评价指标下最优项并不完全相同。其中，SO₂、NO₂、PM_{2.5}、CO 的 MAE 和 RMSE 均为 FNN 占优，O₃ 的 RMSE 为 FNN 最好，而 MAE 为 XGBoost 更佳，总的来说，FNN 在各项评价指标中的表现相对最好

6种常规污染物不同模型评价指标结果比较

问题三

当前广泛应用的空气质量预测二次建模方法有前馈神经网络、随机森林、支持向量回归和极端梯度提升树等，因此使用这 4 种方法分别进行建模，后进行模型择优等处理




③ O3 为二次污染物，是在大气中经过一系列化学及光化学反应生成的，该过程受到一次污染物及气象等的影响，这导致对 **O3 浓度变化的预测难度增高**，故团队将在后文对 O3 进行**单独分析和建模**。

对于除 O3 外的其它 5 种污染物，选择 **FNN 作为其二次预报模型**。

6种常规污染物不同模型评价指标结果比较


问题三

除O₃外5种常规污染物FNN三天预测评价指标结果


由图可知，受不确定性累加的影响，对于大部分污染物模型第二、三天预测效果有所下降。为尽可能提高模型预测效果，以适当加权平均形式得出的组合预测模型，进一步提高预测精度。

基于此，团队将污染物浓度逐小时实测数据也用于建模，并考虑组合多模型对污染物浓度进行预测。

问题三



6种常规污染物不同模型评价指标结果比较




除O₃外5种常规污染物FNN三天预测评价指标结果

从上图可知对于 SO₂ 和 CO， FNN 的 MAE 和 RMSE 三天的数值都相对较低，即模型预测结果误差较小。为精简模型，避免计算资源浪费，团队使用 FNN 作为SO₂ 和 CO 的最终二次预报模型，对于 NO₂、 PM₁₀ 和 PM_{2.5} 则进行进一步修正

对于NO₂、PM₁₀和PM_{2.5}进行进一步修正

- 基于随机森林平均不纯度减少的重要度评价方法对特征进行排序




监测点A特征重要排序情况(实测数据)

对于NO₂、PM₁₀ 和 PM_{2.5} 进行进一步修正


➤ LSTM-FC空气质量二次建模预报模型

考虑到污染物浓度的逐小时实测数据具有较强时序性，所用模型应对此特性加以利用。长短期记忆网络(LSTM)作为循环神经网络的一个变体，有效解决了简单循环神经网络的梯度爆炸或消失问题，在时间序列问题的处理上取得较好表现。故选择 LSTM 作为逐小时实测数据所用模型，此外，为应对 LSTM 输出局限性，即灵活控制预报时长，在其后添加一层全连接层（FC）。



模型组合


经过分析和测试，最终使用 FNN 和 LSTM_FC 的 Lasso 回归组合模型对 NO₂、PM₁₀ 和 PM_{2.5} 进行预测。两种模型预报值通过 Lasso 回归进行组合预测。




NO₂、PM₁₀ 和 PM_{2.5} 的组合模型及 FNN 三天评价指标结果

O3 单独建模与评价

由于 O₃ 本身的特殊性，其预测难度相对更高，需要进行更为精细的处理。经过查阅文献和多次实验，提出了 CEEMDAN_IPSOSE_SVR 方法用于 O₃ 浓度的预测。其中，CEEMDAN 即自适应噪声完备集合经验模态分解，是由 Torres M E.等提出的一种新型信号分解算法，可用于对数据进行降噪；SVR 作为 O₃ 预报模型的基学习器；IPSOSE 是指使用改进的粒子群算法进行寻优和集成




CEEMDAN 分解结果

O₃ 日最大八小时滑动平均监测数据降噪前后对比


O3 单独建模与评价

经过分析，本文使用 CEEMDAN_IPSOSE_SVR 作为 O3 二次预测预测模型。又考虑到合模型可以提高预报准确度，故同样采用经降噪处理后得到的 CEEMDAN_LSTM_FC 模进行组合，得到各模型评价指标结果如下：




O3 单独建模与评价

综上所述，采取的建模流程主要如下图所示



问题四


问题 4 要求建立相邻区域内监测点 A、A1、A2、A3 的协同预报模型，即需在建模过程中对空间相关性加以考虑。为对 4 个监测站点各污染物之间可能存在的空间相关性产生更加科学直观地认识，团队首先采用 Pearson 检验方法，结果如下，发现监测点间具有空间相关性，故考虑使用 GCN 模型进行预测，其余处理方式与问题三一致。



问题四

将 GCN 模型与 GRU_GCN_FC 模型使用 Lasso 回归得到组合模型，用以预测 NO₂、PM₁₀、PM_{2.5}、O₃ 未来三天的污染物浓度值；对于 SO₂ 和 CO，则仍使用 GCN 进行预测。

以下简称问题 4 所用模型为 Q4 模型，问题 3 所用模型为 Q3 模型。



模型评价

- 数据预处理方面：

问题 2 结合风向监测规范内容提出以伪独热码方式处理风向，在保留数据连续性的同时消除其有序性，既具创新性，又符合统计规范，同时为后续分析提供便利

- 模型建立方面：

(1) 问题 3、问题 4 模型首先对经预处理后的多项输入指标采用随机森林平均不纯度减少进行重要度排序，并根据目标污染物的不同自适应选择相应输入指标，有效提升了模型泛化能力。

(2) 问题 3 和问题 4 中分别提出了回归集成模型 **FNN+LSTM_FC+Lasso** 和 **GCN+GRU_GCN_FC+Lasso**，两种模型均能将一次预报数据及实测数据中蕴含的有用信息很好地结合起来进行预报，预测效果相比单模型均有所提升；

模型评价

(3) 针对预测难度较高的 O_3 ，选用更为适应小样本集和鲁棒性较高的支持向量回归作为基学习器并对目标污染物进行 CEEMDAN 降噪，创新性使用 IPSOSE 算法完成基学习器集的择优与集成，从而大幅提升 O_3 预测效果；

(4) 问题 4 中采用图卷积网络 GCN 对空间关系进行聚合。GCN 能较好适应非欧空间关系图，相比传统空间回归模型及卷积神经网络优势更大。



Q & A